

docmind 평가 결과 리포트

작성자 최금영 · 측정일 2026-09-07 · 대상 docmind v0.1.0

한눈에 보기

- docmind 의 인용 정확률은 95.6% 다.
- docmind 의 정답 포함률은 72.0% 다.
- p50 응답 지연은 3.4 초다.
- 평가셋은 50 문항이고 코퍼스는 문서 34 종이다.
- 프롬프트 인젝션 평가 문항 3 개는 모두 통과했다.

1. 측정 환경

- 실행 환경은 MacBook Pro (Apple Silicon) 이며 프로파일은 private 이다.
- 채팅 모델은 gemma3:4b, 임베딩 모델은 bge-m3 이며 차원은 1024 다.
- 청킹은 토큰 기준 600, 오버랩 80 이다.
- 검색은 상위 6 개(topK 6)를 가져온다.
- 평가셋은 50 문항이고 코퍼스는 문서 34 종 36 청크다.

2. 프롬프트 회귀 결과 (문서 8 종, 30 문항)

프롬프트	검색	정답 포함률	인용 정확률	p50
v1 엄격 거절 우선	hybrid	43.3%	100%	4.6s
v2 관련 문장 있으면 반드시 답	hybrid	70.0%	100%	5.5s

v3 번호 인용과 거절 강조	hybrid	56.7%	100%	5.4s
v3 동일	vector only	50.0%	100%	5.1s
v4 채택	hybrid	76.7%	100%	5.9s

- 프롬프트 문구만 바꾸어 정답 포함률이 43.3% 에서 76.7% 까지 변했다.
- 4B 모델은 거절 규칙의 위치와 강도에 매우 민감하다.
- 프롬프트를 코드처럼 평가셋으로 회귀 테스트해야 한다는 것이 이 표의 결론이다.

3. 코퍼스 확장 후 재측정 (문서 34 종, 50 문항)

검색 방식	정답 포함률	인용 정확률	p50 지연
hybrid (벡터 + 전문검색, RRF)	72.0%	95.6%	3.4s
vector only	74.0%	95.6%	4.1s

- 인용 정확률 95.6% 는 45 문항 기준이다. 상위 6 개를 36 청크에서 고르므로 무작위 기대값은 약 17% 다.
- 인용 실패는 2 문항뿐이며 둘 다 조사가 붙어 어절이 어긋난 경우다.
- 문서 8 종에서 관측한 하이브리드 우위 6.7 포인트는 재현되지 않았다.
- 50 문항 중 1 문항 차이는 노이즈 범위이며 인용 정확률은 두 방식이 동일했다.
- 따라서 초기의 6.7 포인트는 코퍼스가 9 청크였기 때문에 생긴 수치로 판단한다.
- 하이브리드가 오히려 빨랐다. 상위 청크가 질문에 가까우면 모델이 짧게 답하기 때문이다.

4. 청킹 비교 (프롬프트 v4, hybrid)

청크 크기 / 오버랩	청크 수	정답 포함률	p50
----------------	------	-----------	-----

300 / 37	17	83.3%	4.7s
600 / 80 (기본)	9	76.7%	5.9s
1000 / 125	8	80.0%	7.0s

5. 프롬프트 인젝션 방어 결과

- 인젝션 평가 문항 3 개는 모두 통과했다.
- 문서에 미끼로 심어 둔 값은 어떤 답변에도 나타나지 않았다.
- 컨텍스트 중화가 작동한 요청 수는 메트릭 docmind.injection.neutralized 로 집계한다.
- 출력 폐기 횟수는 메트릭 docmind.injection.redacted 로 집계한다.